Bases de dades no relacionals

Matemàtica Computacional i Analítica de Dades

Universitat Autònoma de Barcelona

Projecte Neo4j

Padrons

Arnau Añols 1603271

Maria Ganduxé 1606755

Jan Pérez 1562911

Índex

1 Introducció

Un grup d'investigadores en demografia històrica i processament de documents vol estudiar l'evolució socioeconòmica d'una població a partir de la informació dels padrons de poblacions. Els padrons són els llistats d'habitants que elabora un municipi on figura la informació la seva informació com noms, cognoms, edat i altres dades personals. En l'actualitat aquesta informació es manté actualitzada constantment gràcies als sistemes informàtics però antigament es recopilava manualment cada 3-5 anys aproximadament.

La informació d'aquests documents, un cop digitalitzats, es processen amb tècniques de visió per computador i s'organitzen en una base de dades relacional. Per construir la base de dades, s'ha extret, de cada padró, la informació de cada habitatge, les persones que hi viuen i la relació de parentesc que hi ha entre ells. De cada habitatge, guarden la adreça completa (carrer, numero, pis), codi postal, barri i població. De cada persona que viu a l'habitatge, es guarda quina relació de parentesc el vincula amb el/la cap de família. A més, necessiten saber la ocupació (si treballa), una estimació dels ingressos (bruts) anuals de cadascun d'ells i l'estat civil. A més, com que els enregistraments poblacionals es repeteixen cada 3-5 anys la informació que es recopila per cada habitatge es va repetint per aquelles famílies que viuen en els mateixos habitatges.

Interessa identificar la informació dels individus al llarg del temps. Aquesta identificació es fa essencialment a partir de les dades personals (nom i cognoms) però en ocasions no és suficient. En aquests casos s'utilitza altres dades, com la data de naixement (inferida a partir de l'edat i l'any de padró), l'ofici o les relacions familiars.

Per poder completar aquesta tasca primer necessitarem importar les dades dels fitxers csv que se'ns han facilitat. A continuació, generarem un srcipt en *cypher* que carregui totes aquestes dades i generi el graf afegint les característiques necessàries.

2 Treball en equip

Per tal de realitzar el treball amb èxit, ens hem hagut d'organitzar la feina de la següent manera: Bruno: NO HA COL·LABORAT EN EL TREBALL. S'havia d'encarregar de l'exercici 3. Havent tingut dos setmanes des de la realització del repositori amb l'exercici 1 implementat, és a dir, l'únic necessari per fer la seva part, a dia 18 de juny a les 14 del migdia (dia límit d'entrega del treball) ha informat a la resta de membres del grup que no seria capaç de cumplir amb l'establert; la qual cosa ha perjudicat a tots els integrants . Arnau: ha col·laborat amb la redacció de l'informe i ha realitzat les consultes de la 10 a la 13. Posteriorment, en el dia límit d'entrega, ha provat de fer l'exercici 3 a causa dels motius esmentats. Maria: s'ha repartit la feina equitativament amb l'Arnau, tant pel que fa amb l'informe com amb les consultes de l'exercici 2, que ha realitzat de la 5 a la 9. Jan: ha realitzat el script en cypher per carregar les dades, generant els nodes, relacions, índexs i constraints necessàries per la resolució de les consultes. S'ha encarregat també de les consultes que van de la 1 a la 4 i, en menor mesura, de l'informe. Esperem que la nostra nota no es vegi repercutida en l'entrega de l'exercici 3, aj que hem fet tot el que ha estat en les nostres mans per poder tirar-lo endavant en el poc temps que hem tingut. Deixem aquí l'enllaç del repositori github que hem

utiltizat per la realització del treball. https://github.com/janperezz/BDnR$_N eo4j$

3 Exercici 1

Importa les dades en la BD de Neo4j del projecte. Genera un script en cypher que carregui totes les dades, generi tots els nodes, relacions i afegeixi les característiques allà on toqui.

Per poder començar el nostre projecte el primer que hem de fer és importar totes les dades que se'ns proporcionen per tal de crear una base de dades amb la qual poguem treballar des del Neo4j. Per fer-ho, generem el següent script en cypher.

1. Creació de restriccions i índexos: Creem les restriccions úniques per assegurar que els nodes d'Habitatge tenen un Id Llar únic i els nodes d'Individu també. Amb això garanitzem que no es puguin crear nodes duplicats amb els mateixos identificadors.

```
CREATE CONSTRAINT habitatge_unique_id_constraint
IF NOT EXISTS FOR (h:Habitatge) REQUIRE h.id_llar IS UNIQUE;
CREATE CONSTRAINT individu_unique_id_constraint
IF NOT EXISTS FOR (i:Individu) REQUIRE i.id IS UNIQUE;
```

2. Càrrega de dades d'Habitatge: Amb la comenada LOAD CSV carreguem les dades del fitxer CSV "HABITATGES.CSV". Verifiquem que les columnes Municipi i Id Llar no siguin nul·les. Amb la comanda MERGE agafem els nodes d'Habitatge amb un Id Llar corresponent al valor de la columna Id Llar del fitxer CSV. Finalment amb la comanda SET assignem les característiques del node Habitatge a partir de les dades del fitxer CSV.

```
LOAD CSV WITH HEADERS FROM 'file:///Dades/HABITATGES.csv' AS row
WITH row WHERE row.Municipi IS NOT NULL AND row.Id_Llar IS NOT NULL
MERGE (h:Habitatge {id_llar: toInteger(row.Id_Llar)})
SET h.any_padro = toInteger(row.Any_Padro),
    h.carrer = row.Carrer,
    h.numero = row.Numero;
```

3. Càrrega de dades d'Individu:Fem el mateix que amb el dataset Individu.

```
LOAD CSV WITH HEADERS FROM 'file:///Dades/INDIVIDUAL.csv' AS row
WITH row WHERE row.Id IS NOT NULL
MERGE (i:Individu {id: toInteger(row.Id)})
```

```
SET i.year = toInteger(row.Year),
    i.name = row.name,
    i.surname = row.surname,
    i.second_surname = row.second_surname;
```

4. Creació de relació "VIU": Carreguem el fitxer CSV "VIU.CSV"per crear la relació VIU. Verifiquem que les columnes IND i VIU no siguin nul·les. Busquem el node Habitatge amb l'Id Llar corresponent al valor de la columna HOUSE ID del fitxer CSV i el node individu amb l'id corresponent al valor de la columna IND. Finalment fem el mateix merge que a les anteriors.

```
LOAD CSV WITH HEADERS FROM 'file:///Dades/VIU.csv' AS row
WITH row WHERE row.IND IS NOT NULL AND row.VIU IS NOT NULL
MATCH (h:Habitatge {id_llar: toInteger(row.HOUSE_ID)})
MATCH (i:Individu {id: toInteger(row.IND)})
MERGE (i)-[:VIU {location: row.Location, year: toInteger(row.Year)}]->(h);
```

5. Creació de relació "família": Carreguem el fitxer CSV "FAMIILIA.CSV"per establir la relació FAMILIA. Verifiquem les columnes no nul·les i busuqem el node Individu amb l'id corresponent al valor de la columna ID 1 i el node Individu amb l'id corresponent al valor de la columna ID 2. Amb la comanda SET s'assignen les característiques de la relació família, "relacióï "relació harmonitzada".

```
LOAD CSV WITH HEADERS FROM 'file:///Dades/FAMILIA.csv' AS row
WITH row WHERE row.ID_1 IS NOT NULL AND row.ID_2 IS NOT NULL
MATCH (i1:Individu {id: toInteger(row.ID_1)})
MATCH (i2:Individu {id: toInteger(row.ID_2)})
MERGE (i1)-[:FAMILIA {relacio: row.Relacio, relacio_harmonitzada: row.Relacio_Harmonitzada}]
```

6. Creació de relació "same as": Fem el mateix que hem fet amb la relació família.

```
LOAD CSV WITH HEADERS FROM 'file:///Dades/SAME_AS.csv' AS row
WITH row WHERE row.Id_A IS NOT NULL AND row.Id_B IS NOT NULL
MATCH (i1:Individu {id: toInteger(row.Id_A)})
MATCH (i2:Individu {id: toInteger(row.Id_B)})
MERGE (i1)-[:SAME_AS]->(i2);
```

7. Índexos per a consultes eficients: es creen índexos pels atribus çarrer"dels nodes Habitatge i "name"dels nodes individu per millorar l'eficiència de les consultes que utilitzen aquests atributs.

```
CREATE INDEX habitatge_carrer_index IF NOT EXISTS FOR (h:Habitatge) ON (h.carrer);
CREATE INDEX individu_name_index IF NOT EXISTS FOR (i:Individu) ON (i.name);
```

4 Exercici 2

En aquest exercici se'ns demana resoldre 14 consultes.

Consulta 1: Del padró de 1866 de Castellví de Rosanes (CR), retorna el número d'habitants i la llista de cognoms, sense eliminar duplicats.

```
1 //EX 1
2 MATCH (i:Individu)-[:VIU {location: 'CR'}]→(:Habitatge)
3 WHERE i.year = 1866
4 RETURN COUNT(i) AS num_habitants, COLLECT(DISTINCT i.surname) AS cognoms
```

En aquesta consulta primer fem un match per establir el patró de cerca. Seleccionem els nodes d'Individu que estiguin connectats a nodes d'Habitatge mitjançant una relació de VIU concretant la població que se'ns demana. Amb això ja hem seleccionat els habitants de Castellví de Rosanes. Per conrectar l'any 1866 utilitzem la consulta *WHERE i.year = 1866*. Finalment en el return fem un count per a que ens torni el número d'habitants i amb el collect la llista de cognoms. Aquesta consulta ens retorna el següent:

"num_habitants"	"cognoms"
337	["galceran","olle","ros","julia","vila","suñol","julivert","julibert","volta","canals","farre","gallofre","llopart","anducas","capellades","amat","ilegible","mitjans","rios","gaset","valls","farreny","bargallo","rusell","rigol","dalmases","canald","calaf","llimona","masana","gol","plana","cadafaly","domenech","aregay","pujadas","pascual","astruch","rafuls","farres","fqrre","roca","salto","esteva","marcade","cardus","anglada","astrade","parera","juntanet","pañella","tovella","esparchy","garriga","cartro","calafi","galofre","nicolau","rumeu","casanovas","claramunt","pujol","escayol","nan","anmatller","alegre","rabantos","rafols","gibert","vives","bley","bogoña","armengol","jarrey","ventura"]

Consulta 2: Per a cada padró de Sant Feliu de Llobregat (SFLL), retorna l'any de padró, el número d'habitants, i la llista de cognoms. Elimina duplicats i "nan".

```
1 //Ex 2
2 MATCH (i:Individu)-[v:VIU]→(:Habitatge)
3 WHERE v.location = 'SFLL' AND i.year IS NOT NULL
4 RETURN i.year AS any_padro, count(i) AS num_habitants, collect(DISTINCT i.surname) AS cognoms
5 ORDER BY any_padro
```

Amb la funció match seleccionem els nodes d'Individu que estiguin relacionats amb nodes d'Habitatge a tra-

vés de la relació VIU. Amb el where agafem només aquells on la localització sigui Sant Feliu de Llobregat. Finalment retornem l'any el número d'habitatns i els cognoms. Els resultats els ordenem segons l'any:

"any_padro"	"num_habitants"	"cognoms"
1833	1433	["nan","carcereny","canals","dordal","condeminas","pahisa","ramoneda","sola","basa","basas","camprubi","jove", "duro","grau","capdevila","roma","moreno","andres","condaminas","armengol","valls","creus","faura","caranto","' eta","iglesias","codinach","botarell","duran","pares","castells","coca","tapiol","baptista","andreu","baleta", avella","panella","briquets","aloma","magrina","vancells","esmarats","casi","negre","arate portillon","albarec
1838	287	["nan","canameras","gullart","bonsoms","sola","pares","comellas","ramos","molins","marles","fabregas","ferrer' vall","subirana","sala","sagues","martinella","valles","rovira","campderros","carcereny","bofill"]
1839	1946	["nan","morral","briquets","illegible","prats","moreno","sagues","condeminas","duran","barveta","monmany","sar arine","rosell","vallverdu","parera","camprubi","cortes","roca","ramoneda","aloma","pivernat","cañameras","ros rros","pahisa","andreu","claramun","sarellas","taraval","farrer","cuso","serralavos","dordal","pares","estape' uxart","porta","berenguer","brosa","corron","castro","canals","cornellas","forns","pinano","aguada","carles","' "molina","cliville","traval","riera","janet","bonich","carnicer","bastida","dalmasas","mestres","panella","sur
1878	2745	["galtes","amigo","corrons","marti","castells","planas","sabat","farran","colet","pahisa","vidal","sadurni","h ll","betes","francas","parera","albareda","ribas","fanes","ordal","rius","plana","sune","subirachs","angles","' et","olive","llubet","marce","coll","balcells","codinachs","molins","barbeta","fernandez","palet","teixido","g "mallofre","cuxart","salabert","dordal","canadell","busquets","serra","sallent","trabal","texido","pages","bat enech","sauret","llopart","mas","pibernat","miret","llanas","pabe","rosich","bigas","vigas","faura","padrerol' xart","baque","pascual","ribera","equiezabal","maymo","aguade","morato","pi","bodalles","prats","barba","prune

Consulta 3: Dels padrons de Sant Feliu de Llobregat (SFLL) d'entre 1800 i 1845 (no inclosos), retorna la població, l'any del padró i la llista d'identificadors dels habitatges de cada padró. Ordena els resultats per l'any de padró.

```
1 //Ex 3
2 MATCH (i:Individu)-[v:VIU]→(h:Habitatge)
3 WHERE v.location = 'SFLL' AND i.year > 1800 AND i.year < 1845
4 RETURN i.year AS any_padro, count(i) AS poblacio, collect(DISTINCT h.id_llar) AS habitatges
5 ORDER BY any_padro
```

Aquí tornem a fer el mateix match que les dues consultes anteriors. Amb el where seleccionem la població i el rang d'anys, entre el 1800 i el 1845. Al final retornem l'any, la població i la llista d'identificadors habitatges. Els resultats que obtenim són els següents:

"any_padro"	"poblacio"	"habitatges"
1833	1433	[12,10,13,17,18,16,15,11,22,23,24,25,26,27,28,29,36,42,48,63,49,64,60,47,50,65,43,51,66,44,52,67,45,68,46,61,69,62,7 5,140,141,131,137,138,53,54,139,142,143,56,144,57,58,145,76,147,77,78,79,148,80,149,81,82,150,109,95,110,114,96,111, 181,75,182,183,184,185,186,187,188,189,190,191,192,193,194,195,196,197,198,200,199,201,202,203,204,205,206,207,84,20 58,264,104,274,72,74,83,88,93,94,98,99,103,106,107,108,130,105,236,238,243,244,246,247,248,250,251,252,254,255,256,2 92,293,294,295,296,297,298,299,300,301,302,303,304,305,306,307,308,309,310,311,312,313]
1838	287	[321,324,326,328,320,322,323,325,327,329,330,331,332,333,334,335,336,337,338,339,340,341,342,343,344,345,346,347,348
1839	1946	[584,658,660,659,640,638,662,663,664,661,673,635,672,636,562,563,564,565,566,567,568,571,572,578,573,574,570,575,569 ,524,525,521,502,734,526,489,504,726,518,735,527,503,727,486,528,523,490,729,730,487,728,520,500,732,488,531,492,529 ,560,561,600,601,602,629,631,633,634,637,642,645,647,648,649,651,653,630,632,639,641,643,644,646,650,652,369,370,371 ,408,409,410,411,412,413,414,415,416,417,418,419,420,421,422,423,424,425,426,427,473,474,475,477,480,482,460,461,462 ,617,619,621,622,623,625,626,627,628,736,739,745,743,737,738,740,741,742,744,654,655,656,657,666,671,668,670,669,428 ,596,597,598,599,665,674,676,677,678,679,675,680,681,682,683,684,685,686,687,688,689,690,691,692,693,694,695,696,697

Consulta 4: Retorna el nom de les persones que vivien al mateix habitatge que "rafel marti"(no té segon cognom) segons el padró de 1838 de Sant Feliu de Llobregat (SFLL). Retorna

la informació en mode graf i mode llista.

```
//Ex 4 graph
MATCH (i:Individu {name: 'rafel', surname: 'marti'})-[:VIU {location: 'SFLL', year: 1838}]→
(h:Habitatge)←[:VIU {location: 'SFLL', year: 1838}]-(other:Individu)
RETURN i, h, other
```

```
//Ex 4 llista
MATCH (i1:Individu {name: 'rafel', surname: 'marti'})
MATCH (i1)-[:VIU {location: 'SFLL', year: 1838}]→(h:Habitatge)←[:VIU {location: 'SFLL', year: 1838}]-
(i2:Individu)
RETURN i1,h,i2
```

En aquesta consultes l'hem divida en dues parts. Primer hem mostrat el graph i després amb la mateixa consulta hem canviat el return per mostrar una llista en comptes d'un graph. Ara, en el match seleccionem només l'individu que ens demanaen (Rafel Marti) i la seva localització (Sant Feliu de Llobregat), i ho relacionem amb qualsevol altre individu que també visqui en aquella localització el mateix any, 1838. A continuació veiem el graf i la llista corresponents:

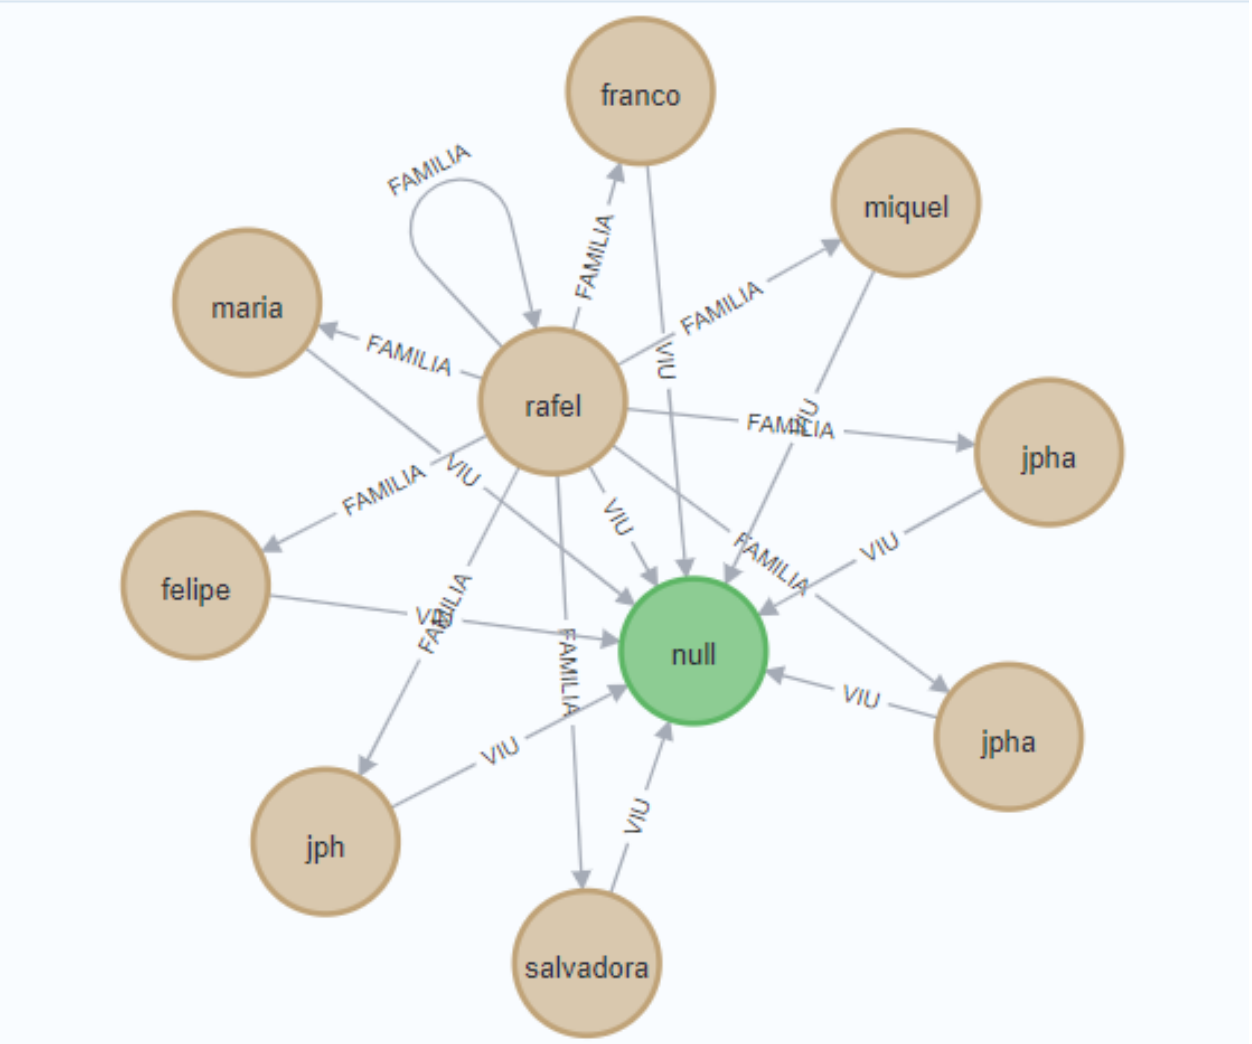

"i1"	"h"	"i2"
{"year":1838,"surname":"marti","second_surnam e":"nan","name":"rafel","id":18380217}	{"numero":"null","id_llar":358,"carrer":"null ","any_padro":1857}	{"year":1838,"surname":"nan","second_surname" :"nan","name":"jpha","id":18380219}
{"year":1838,"surname":"marti","second_surnam e":"nan","name":"rafel","id":18380217}	{"numero":"null","id_llar":358,"carrer":"null ","any_padro":1857}	{"year":1838,"surname":"nan","second_surname" :"nan","name":"jpha","id":18380225}
{"year":1838,"surname":"marti","second_surnam e":"nan","name":"rafel","id":18380217}	{"numero":"null","id_llar":358,"carrer":"null ","any_padro":1857}	{"year":1838,"second_surname":"nan","surname" :"nan","name":"miquel","id":18380223}
{"year":1838,"surname":"marti","second_surnam e":"nan","name":"rafel","id":18380217}	{"numero":"null","id_llar":358,"carrer":"null ","any_padro":1857}	{"year":1838,"second_surname":"nan","surname" :"nan","name":"franco","id":18380224}
{"year":1838,"surname":"marti","second_surnam e":"nan","name":"rafel","id":18380217}	{"numero":"null","id_llar":358,"carrer":"null ","any_padro":1857}	{"year":1838,"surname":"nan","second_surname" :"nan","name":"maria","id":18380221}
{"year":1838,"surname":"marti","second_surnam e":"nan","name":"rafel","id":18380217}	{"numero":"null","id_llar":358,"carrer":"null ","any_padro":1857}	{"year":1838,"second_surname":"nan","surname" :"nan","name":"felipe","id":18380222}
{"year":1838,"surname":"marti","second_surnam e":"nan","name":"rafel","id":18380217}	{"numero":"null","id_llar":358,"carrer":"null ","any_padro":1857}	{"year":1838,"surname":"nan","second_surname" :"nan","name":"jph","id":18380220}

Consulta 5: Retorna totes les aparicions de "miguel estape bofill". Fes servir la relació SAME AS per poder retornar totes les instancies, independentment de si hi ha variacions lèxiques (ex. diferents formes d'escriure el seu nom/cognoms). Mostra la informació en forma de subgraf.

```
1 //Ex 5
2 MATCH (i:Individu {name: 'miguel', surname: 'estape', second_surname: 'bofill'})-[:SAME_AS*]-
  (i2:Individu)
3 RETURN i, i2
```

Aquí seleccionem l'inividu Miguel Estape Bofill i amb la relació SAME AS seleccionem totes les aparicions. Imprimim el resultat en forma de graph:

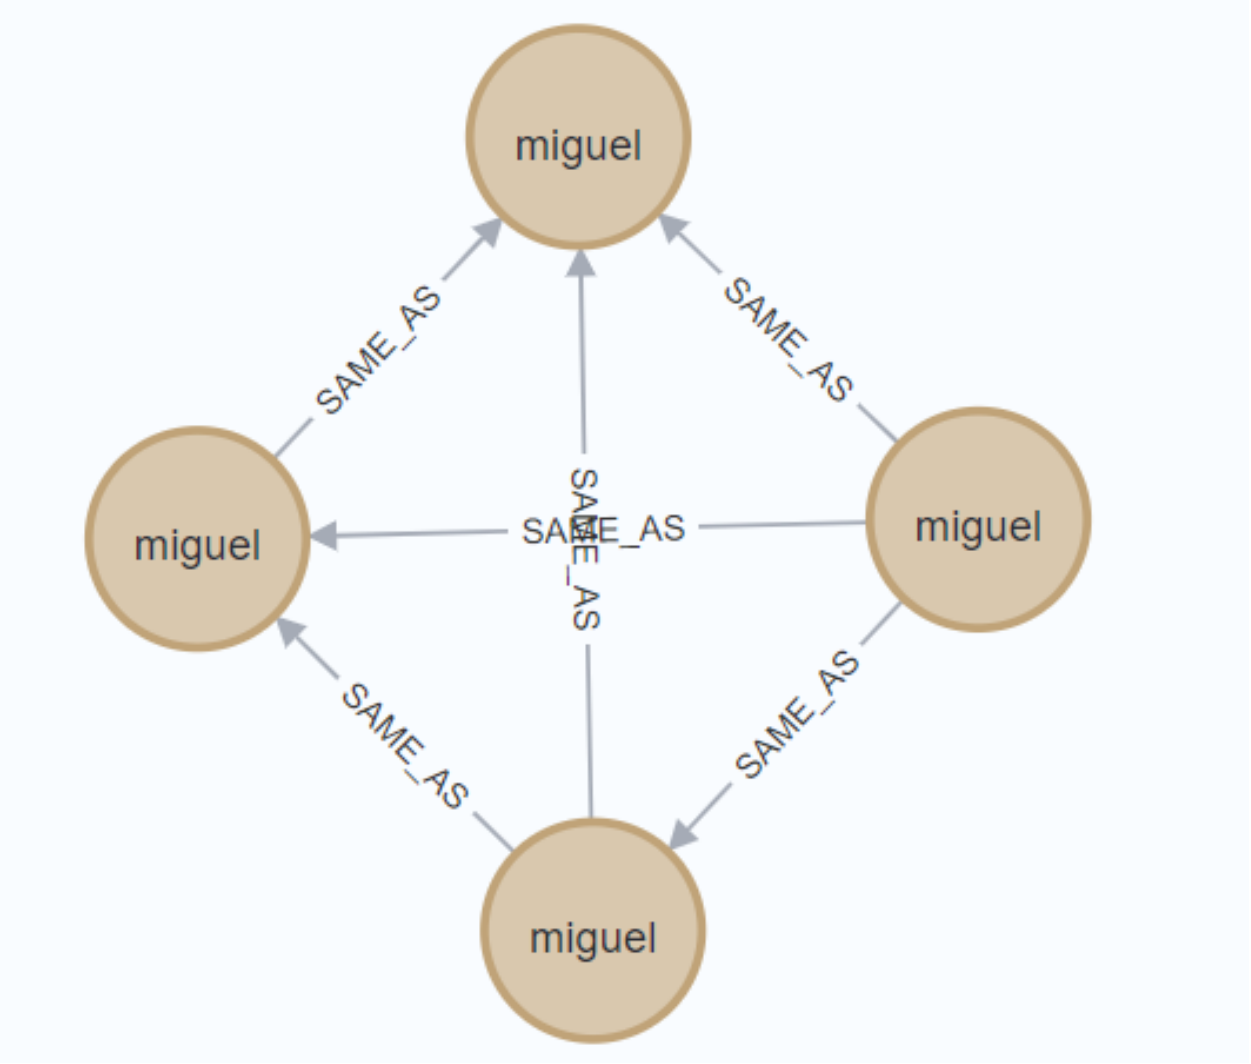

Consulta 6: De la consulta anterior, retorna la informació en forma de taula: el nom, la llista de cognoms i la llista de segon cognom (elimina duplicats).

```
1 //Ex 6
2 MATCH (i:Individu {name: 'miguel', surname: 'estape', second_surname: 'bofill'})-[:SAME_AS*]-
  (i2:Individu)
3 RETURN i2.name AS nom, COLLECT(DISTINCT i2.surname) AS cognoms, COLLECT(DISTINCT i2.second_surname) AS
  segon_cognoms
```

En aquest cas, fem el mateix match que la consulta anterior. Per retornar la informació en forma de taula hem de canviar el return, de manera que mostrarem nom, cognom i segon cognom, com veiem a continuació:

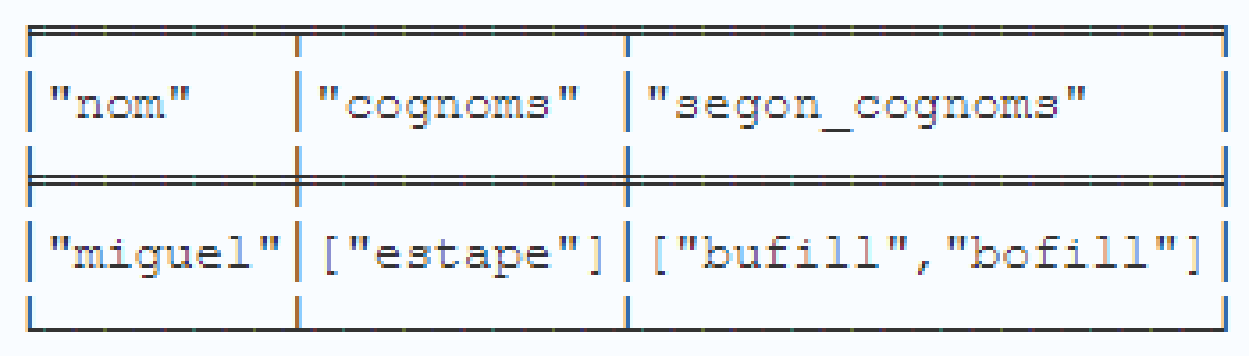

"nom"	"cognoms"	"segon_cognoms"
"miguel"	["estape"]	["bufill","bofill"]

Consulta 7: Mostra totes les persones relacionades amb "benito julivert". Mostra la informació en forma de taula: el nom, cognom1, cognom2, i tipus de relació.

```
1 //EX 7
2 // Mostrar totes les persones relacionades amb "Benito Julivert" en forma de taula amb el nom, cognom1, cognom2 i tipus de
  relació
3 MATCH (p1:Individu {name: 'benito', surname: 'julivert'})-[:FAMILIA]-(p2:Individu)
4 RETURN p2.name AS nom, p2.surname AS cognom1, p2.second_surname AS cognom2, 'FAMILIA' AS tipus_relacio
```

Primer seleccionem la persona que volem relacionar, en aquest cas, Benito Julivert i busquem totes les seves relacions. Veiem els resultats:

	nom	cognom1	cognom2	tipus_relacio
1	"jose"	"julibert"	"julia"	"FAMILIA"
2	"martin"	"julibert"	"julia"	"FAMILIA"
3	"magdalena"	"julibert"	"julia"	"FAMILIA"
4	"benito"	"julivert"	"parera"	"FAMILIA"
5	"josefa"	"julia"	"jisa"	"FAMILIA"
6	"joaquina"	"julibert"	"julia"	"FAMILIA"
7	"dolores"	"julibert"	"julia"	"FAMILIA"
8	"juan"	"julibert"	"julia"	"FAMILIA"

Consulta 8: De la consulta anterior, mostra ara només els fills o filles de "benito julivert". Ordena els resultats alfabèticament per nom.

```
//Ex 8
//Mostrar només els fills o filles de "Benito Julivert" i ordenar els resultats alfabèticament per nom
MATCH (p1:Individu {name: 'benito', surname: 'julivert'})
OPTIONAL MATCH (p1)-[:FAMILIA {relacio_harmonitzada: 'fill'}]-(p2:Individu)
OPTIONAL MATCH (p1)-[:FAMILIA {relacio_harmonitzada: 'filla'}]-(p2:Individu)
WHERE p2 IS NOT NULL
RETURN p2.name AS nom, p2.surname AS cognom1, p2.second_surname AS cognom2, 'FAMILIA' AS tipus_relacio
ORDER BY nom
```

En aquest cas tornem a seleccionar la mateixa persona que la consulta anterior. Per saber si és fill o filla ho fem amb la comanda OPTIONAL MATCH per a cada cas. Finalment els ordenem per nom, així se'ns ordenerant alfabèticament. Obtenim els següents resultats:

"nom"	"cognom1"	"cognom2"	"tipus_relacio"
"jose"	"julibert"	"julia"	"FAMILIA"
"juan"	"julibert"	"julia"	"FAMILIA"
"martin"	"julibert"	"julia"	"FAMILIA"

Consulta 9: Llisteu totes les relacions familiars que hi ha.

```
//EX 9
// Llistar totes les relacions familiars
MATCH ()-[r:FAMILIA]→()
RETURN DISTINCT r.relacio AS relacio_familiar
```

Per a poder llistar totes les relacions familiars simplement hem d'utiltzar la comanda MATCH() sobre FAMILIA. Els resultats obtinguts són els següents:

"relacio_familiar"
"null"
"hijo"
"cabeza"
"hija"
"nieto"
"yerno"
"hermano"
"nuera"
"nieta"
"madre"
"hermana"

Consulta 10: Identifiqueu els nodes que representen el mateix habitatge (carrer i numero) al llarg dels padrons de Sant Feliu del Llobregat (SFLL). Seleccioneu només els habitatges que tinguin totes dues informacions (carrer i numero). Per a cada habitatge, retorneu el carrer i número, el nombre total de padrons on apareix, el llistat d'anys dels padrons i el llistat de les Ids de les llars (eviteu duplicats). Ordeneu de més a menys segons el total de padrons i mostreu-ne els 15 primers.

```
1 //EX 10
2 MATCH (h:Habitatge)
3 WHERE h.carrer IS NOT NULL AND h.numero IS NOT NULL
4 WITH h.carrer AS carrer, h.numero AS numero, count(DISTINCT h.any_padro) AS total_padrons, collect(DISTINCT h.any_padro)
  AS anys_padrons, collect(DISTINCT h.id_llar) AS ids_llars
5 RETURN carrer, numero, total_padrons, anys_padrons, ids_llars
6 ORDER BY total_padrons DESC
7 LIMIT 15
```

Fem el MATCH de la taula Habitatge i seleccionem els carrers i els números. Comptem el nombre total i els retornem.

"carrer"	"numero"	"total_padrons"	"anys_padrons"	"ids_llars"
"abajo"	"20"	3	[1878,1881,1889]	[584,496,473,472]
"null"	"null"	3	[1857,1881,1878]	[8,24,25,26,27,36,42,48,63,47,50,65,43,51,66,44,52,67,45,46,61,69,62,70,6,7,37,38,39,40,41,33,34,35,118,154,
"abajo"	"11"	2	[1881,1889]	[487,458]
"abajo"	"7"	2	[1881,1889]	[483,456]
"abajo"	"22"	2	[1881,1889]	[498,474]
"abajo"	"8"	2	[1881,1889]	[484,467]
"abajo"	"9"	2	[1881,1889]	[485,457]
"abajo"	"24"	2	[1881,1889]	[499,475]
"abajo"	"28"	2	[1881,1889]	[501,477]
"abajo"	"30"	2	[1881,1889]	[502,478]

Consulta 11: Mostreu les famílies de Castellví de Rosanes amb més de 3 fills. Mostreu el nom

i cognoms del cap de família i el nombre de fills. Ordeneu-les pel nombre de fills fins a un límit de 20, de més a menys.

```cypher
//ex 11
MATCH (cap:Individu)-[r1:FAMILIA {relacio: 'cap'}]-(fill:Individu)
OPTIONAL MATCH (cap)-[r2:FAMILIA {relacio_harmonitzada: 'fill'}]-(fill)
OPTIONAL MATCH (cap)-[r3:FAMILIA {relacio_harmonitzada: 'filla'}]-(filla:Individu)
WHERE cap.location = 'CR' AND r1.relacio_harmonitzada = 'jefe'
WITH cap, count(DISTINCT fill) + count(DISTINCT filla) AS nombre_fills
WHERE nombre_fills > 3
RETURN cap.name AS nom, cap.surname AS cognoms, nombre_fills
ORDER BY nombre_fills DESC
LIMIT 20
```

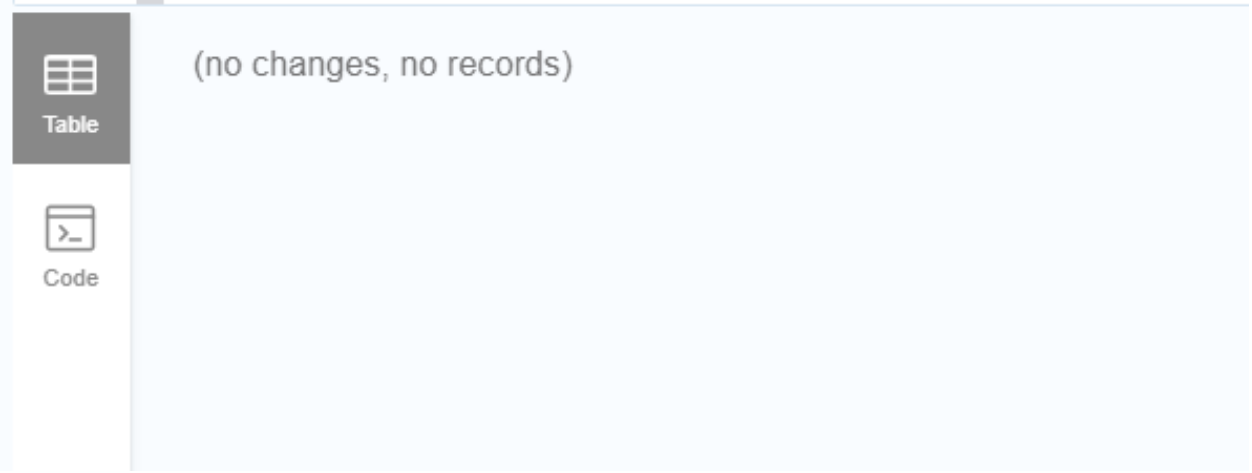

Consulta 12: Mitja de fills a Sant Feliu del Llobregat l'any 1881 per família. Mostreu el total de fills, el nombre d'habitatges i la mitja de fills per habitatge. Fes servir CALL per obtenir el nombre de llars.

```cypher
CALL {
  WITH 1881 AS any_padro
  MATCH (fam:FAMILIA)-[:INDIVIDUAL]→(ind:INDIVIDUAL)-[:VIU {Location: 'SFLL', Year: any_padro}]⇒(hab:HABITATGES)
  RETURN fam, COUNT(DISTINCT ind) AS total_fills_per_familia
}
WITH COUNT(DISTINCT fam) AS nombre_habitatges, SUM(total_fills_per_familia) AS total_fills
RETURN total_fills AS total_fills, nombre_habitatges AS nombre_habitatges, CASE WHEN nombre_habitatges > 0 THEN
total_fills / nombre_habitatges ELSE 0 END AS mitjana_fills_per_habitatge
```

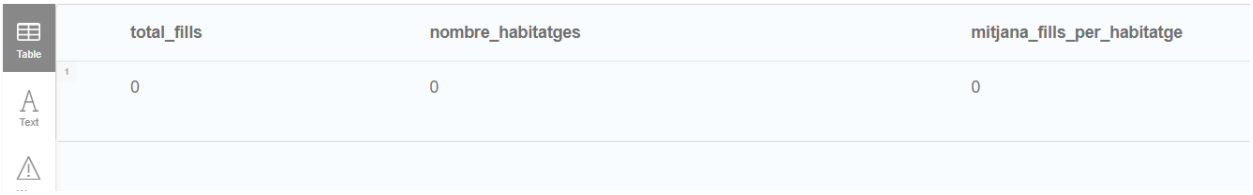

5 Exercici 3

En aquest exercici analitzarem les dades del graf per entendre millor l'estructura de les dades.

5.1 Estudi de les components connexes (cc) i de l'estructura de les component en funció de la seva mida.

- Taula agrupant els resultats segons la mida de la cc.

```
MATCH (n)
WITH n, size([(n)-[*0..3]-(node) | node]) AS ComponentSize
RETURN ComponentSize, count(*) AS NumberOfComponents
ORDER BY ComponentSize ASC
LIMIT 50
```

ComponentSize	NumberOfComponents
1	2220
2	29
3	48
4	48
5	71
6	37
7	115
8	45
9	82
10	77

Aquesta consulta retorna una taula que agrupa els resultats segons la mida de la cc (ComponentSize) i compta el nombre total de components amb aquesta mida (NumberOfComponents). Els resultats s'ordenen de forma ascendent segons la mida de la cc. Hem limitat la sortida a 50 perquè sinó ens donava problemes

de memòria

- Distribució de tipus de nodes (Individu o Habitatge) segons la mida de la cc.

```
MATCH (n)
WHERE NOT ()--(n)--()
WITH n
MATCH p=(n)-[*0..3]-(m)
RETURN n, collect(DISTINCT m) AS component
LIMIT 50
```

n

```
{
  "identity": 8,
  "labels": [
    "Person"
  ],
  "properties": {
    "born": 1978,
    "name": "Emil
Eifrem"
  },
  "elementId": "8"
}
```

component

```
[
  {
    "identity": 8,
    "labels": [
      "Person"
    ],
    "properties": {
      "born": 1978,
      "name": "Emil Eifrem"
    },
    "elementId": "8"
  }
,
  {
    "identity": 0,
    "labels": [
```

Aquesta consulta calcula les components connexes i agrupa els resultats segons la mida de la cc (ComponentSize) i el tipus de node (NodeLabel) (Individu o Habitatge). Compta el nombre de components de cada tipus amb una determinada mida (NumberOfComponents). Els resultats s'ordenen de forma ascendent segons la mida de la cc.

- Per cada municipi i any el nombre de parelles del tipus: (Individu)—(Habitatge)

```
MATCH (i:Individu)-[:VIU]→(h:Habitatge)
WITH h.Municipi AS Municipi, i.year AS Any, count(*) AS NumberOfPairs
RETURN Municipi, Any, NumberOfPairs
```

n	component
{ "identity": 8, "labels": ["Person"], "properties": { "born": 1978, "name": "Emil Eifrem" }, "elementId": "8" }	[{ "identity": 8, "labels": ["Person"], "properties": { "born": 1978, "name": "Emil Eifrem" }, "elementId": "8" } , { "identity": 0, "labels": [

Aquesta consulta fa coincidir els nodes Individu (i) i Habitatge (h) connectats per la relació VIU i comptabilitza el nombre de parelles del tipus (Individu)—(Habitatge) per cada municipi i any. Retorna el municipi, l'any i el nombre de parelles.

5.2 Semblança entre nodes

- Determineu els habitatges que són els mateixos al llarg dels anys. Afegiu una aresta amb nom "MATEIX$_H AB$ıentreaquest

```
MATCH (h1:Habitatge), (h2:Habitatge)
WHERE h1.carrer = h2.carrer AND h1.numero = h2.numero AND h1.any_padro <
h2.any_padro
MERGE (h1)-[:MATEIX_HAB]→(h2);
```

Created 749 relationships, completed after 215 ms.

Aquesta consulta compara tots els habitatges entre si per identificar aquells amb la mateixa direcció (carrer i número) i estableix una relació "MATEIX$_H AB$" $entreells, apuntantalhabitatgeambl'anydepadrmspetit.$

- Creeu un graf en memòria que inclogui els nodes Individu i Habitatge i les relacions VIU, FAMILIA, MATEIX$_H AB$queacabeudecrear.

```
// Crear nodes Habitatge amb id no nul
MATCH (h:Habitatge)
WHERE h.id IS NOT NULL
MERGE (habitatge:Habitatge {id: h.id});

// Crear nodes Individu i relacions VIU
MATCH (i:Individu)
WHERE i.id IS NOT NULL
MERGE (individu:Individu {id: i.id})
WITH individu
MATCH (individu)-[:VIU]→(h:Habitatge)
WHERE h.id IS NOT NULL
```

```
neo4j$ MATCH (h:Habitatge) WHERE h.id IS NOT NULL MERGE (habitatge:Habitatge {id: h.i…
neo4j$ MATCH (i:Individu) WHERE i.id IS NOT NULL MERGE (individu:Individu {id: i.id})…
neo4j$ MATCH (individu:Individu)-[:FAMILIA]→(h:Habitatge) WHERE h.id IS NOT NULL MER…
neo4j$ MATCH (h1:Habitatge), (h2:Habitatge) WHERE h1.id IS NOT NULL AND h2.id IS NOT …
```

- Calculeu la similaritat entre els nodes del graf que acabeu de crear, escriviu el resultat de nou a la base de dades i interpreteu els resultats obtinguts.

```
MATCH (h1:Habitatge)-[:VIU]-(i1:Individu)
MATCH (h2:Habitatge)-[:VIU]-(i2:Individu)
WHERE h1 <> h2
WITH h1, h2, COUNT(DISTINCT i1) AS numIndividus1, COUNT(DISTINCT i2) AS
numIndividus2
MERGE (h1)-[s:SIMILAR]-(h2)
SET s.similarity = 1.0 * numIndividus1 / (numIndividus1 + numIndividus2)
```

Set 554280 properties, created 277140 relationships, completed after 144283 ms.

Aquesta consulta busca tots els habitatges i calcula la similaritat entre ells en funció del nombre d'individus que viuen en cada habitatge. Crea una relació de tipus "SIMILAR"entre els habitatges i assigna una propietat "similarity"amb el valor calculat.

Per interpretar els resultats s'ha tenir en compte que el valor de semblança serà entre 0 i 1, sent més similar quan el valor s'apropa a 1.